

LAPORAN MACHINE LEARNING



Disusun Oleh:

Nama : Algedian Syahtria Wangsa, Okta Kurnia Ariansyah

NPM : G1A024071, G1A024099

Kelas : A

Dosen Pengampu :

1. Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.
2. Ir. Kurnia Anggriani, S.T., M.T., Ph.D.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

B.1 Kode Membaca Dataset :

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
df = pd.read_csv("mahasiswa_lulus.csv")
print("5 Data Pertama:")
print(df.head())
print("\nUkuran Dataset:")
print(df.shape)
Hasil :
```

```
=====
DATASET
=====

5 Data Pertama:
|   IPK  Kehadiran  Jam_Belajar  ...  Jenis_Kelamin  Status_Beasiswa  Lulus_Tepat_Waktu
0  3.36      93.3         5.2  ...    Perempuan      Tidak          Ya
1  3.09     100.0         4.5  ...    Perempuan      Tidak          Ya
2  3.42      70.0         3.3  ...    Perempuan        Ya          Tidak
3  3.79      89.6         2.3  ...     Laki-laki        Ya          Ya
4  3.05      77.5         4.2  ...     Laki-laki      Tidak          Tidak

[5 rows x 8 columns]

Ukuran Dataset:
(500, 8)
```

B.2 Preprocessing Data

1. Kode yang digunakan Untuk Pengecekan Missing Value:

```
print("\nJumlah Missing Value:")
print(df.isnull().sum())
```

Hasil :

```
IPK          0
Kehadiran    0
Jam_Belajar  0
Organisasi   0
Penghasilan_Ortu  0
Jenis_Kelamin  0
Status_Beasiswa  0
Lulus_Tepat_Waktu  0
dtype: int64
```

2. Kode yang digunakan untuk Penanganan Missing Value :

```
kolom_numerik = ["IPK", "Kehadiran", "Jam_Belajar"]
```

```
kolom_kategorikal = [
```

```
    "Organisasi",
```

```
    "Penghasilan_Ortu",
```

```
    "Jenis_Kelamin",
```

```
    "Status_Beasiswa"
```

```
]
```

```
for kolom in kolom_numerik:
```

```
    df[kolom] = df[kolom].fillna(df[kolom].median())
```

```
for kolom in kolom_kategorikal:
```

```
    df[kolom] = df[kolom].fillna(df[kolom].mode()[0])
```

Hasil :

```
Jumlah Missing Value Setelah Preprocessing:
IPK                  0
Kehadiran            0
Jam_Belajar          0
Organisasi           0
Penghasilan_Ortu     0
Jenis_Kelamin        0
Status_Beasiswa      0
Lulus_Tepat_Waktu    0
dtype: int64
```

3. Kode Encoding Data Kategorikal :

```
from sklearn.preprocessing import LabelEncoder
```

```
encoder = LabelEncoder()
```

```
kolom_encoding = [
```

```
    "Organisasi",
```

```
    "Penghasilan_Ortu",
```

```
    "Jenis_Kelamin",
```

```
    "Status_Beasiswa",
```

```
    "Lulus_Tepat_Waktu"
```

```
]
```

```
for kolom in kolom_encoding:
```

```
df[kolom] = encoder.fit_transform(df[kolom])
```

Hasil :

```
Data Setelah Encoding:
|   IPK  Kehadiran  ...  Status_Beasiswa  Lulus_Tepat_Waktu
0  3.36      93.3  ...                0                1
1  3.09     100.0  ...                0                1
2  3.42      70.0  ...                1                0
3  3.79      89.6  ...                1                1
4  3.05      77.5  ...                0                0

[5 rows x 8 columns]
```

4. Pembagian Data Training dan Testing

Kode :

```
X = df.drop("Lulus_Tepat_Waktu", axis=1)
y = df["Lulus_Tepat_Waktu"]
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)
```

Hasil:

```
Fitur yang digunakan:
Index(['IPK', 'Kehadiran', 'Jam_Belajar', 'Organisasi', 'Penghasilan_Ortu',
      'Jenis_Kelamin', 'Status_Beasiswa'],
      dtype='str')

Jumlah Data Setiap Kelas:
Lulus_Tepat_Waktu
1      250
0      250
Name: count, dtype: int64

Jumlah Data Training: 400
Jumlah Data Testing : 100
```

Analisis :

Tahapan preprocessing menghasilkan data yang sudah siap digunakan untuk proses pemodelan. Tidak terdapat missing value, seluruh variabel kategorikal telah dikonversi menjadi numerik, dan


dataset telah dibagi menjadi data training dan testing dengan perbandingan 80:20. Selanjutnya, data training digunakan untuk melatih tiga model yang akan dibandingkan.

B.3 Pembuatan Model

Kode Pemodelan :

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.naive_bayes import GaussianNB
model_dt_3 = DecisionTreeClassifier(
    max_depth=3,
    random_state=42
)
model_dt_none = DecisionTreeClassifier(
    max_depth=None,
    random_state=42
)
model_nb = GaussianNB()
model_dt_3.fit(X_train, y_train)
model_dt_none.fit(X_train, y_train)
model_nb.fit(X_train, y_train)
```

Hasil :



```
Ketiga model berhasil dilatih.
```

Analisis :

Penggunaan dua konfigurasi Decision Tree memungkinkan perbandingan antara pohon yang dibatasi kedalamannya dengan pohon yang tidak dibatasi. Sementara itu, Gaussian Naive Bayes digunakan sebagai model pembanding dengan pendekatan probabilistik.

B.4 Evaluasi Model

Kode Evaluasi :

```
from sklearn.metrics import (
```

```

accuracy_score,
precision_score,
recall_score,
f1_score,
confusion_matrix
)
y_pred_dt_3 = model_dt_3.predict(X_test)
y_pred_dt_none = model_dt_none.predict(X_test)
y_pred_nb = model_nb.predict(X_test)
def hitung_metrik(y_test, y_pred):
    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(
        y_test, y_pred, zero_division=0
    )
    recall = recall_score(
        y_test, y_pred, zero_division=0
    )
    f1 = f1_score(
        y_test, y_pred, zero_division=0
    )
    return accuracy, precision, recall, f1

```

Hasil :

```

=====
HASIL EVALUASI MODEL
=====

```


	Model	Accuracy	Precision	Recall	F1-Score
	Decision Tree (max_depth=3)	0.68	0.6500	0.78	0.7091
	Decision Tree (max_depth=None)	0.62	0.6200	0.62	0.6200
	Gaussian Naive Bayes	0.77	0.7755	0.76	0.7677

Analisis :

Berdasarkan hasil pengujian, **Gaussian Naive Bayes memiliki kinerja paling baik** dibandingkan kedua model Decision Tree. Model ini memperoleh Accuracy sebesar **77%**, Precision **77,55%**, Recall **76%**, dan F1-Score **76,77%**.


B.5 Visualisasi Hasil

1. Visualisasi Decision Tree



Gambar 1. Visualisasi Decision Tree dengan max_depth=3

2. Perbandingan Metrik Model



Gambar 2. Perbandingan Kinerja Ketiga Model

B.6 Kode Analisis 5 Data yang Salah Diprediksi:

```
data_analisis = X_test.copy()
data_analisis["Aktual"] = y_test
```

```

data_analisis["Prediksi"] = y_pred_nb
data_salah = data_analisis[
    data_analisis["Aktual"] != data_analisis["Prediksi"]
]
print(data_salah.head(5).to_string())

```

```
=====
5 DATA YANG SALAH DIPREDIKSI
=====
```

	IPK	Kehadiran	Jam_Belajar	Organisasi	Penghasilan_Ortu	Jenis_Kelamin	Status_Beasiswa	Aktual	Prediksi
212	3.55	78.6	2.2	0	1	1	0	0	1
443	3.11	83.0	1.4	1	0	1	0	1	0
290	3.06	88.3	3.7	0	0	0	0	1	0
89	3.37	75.4	2.9	0	0	0	0	1	0
373	3.55	76.7	0.9	0	1	0	0	0	1

Analisis :

Berdasarkan beberapa data yang mengalami kesalahan prediksi, terlihat bahwa model belum selalu mampu menentukan status kelulusan dengan tepat. Pada data 212 dan 373, IPK yang cukup tinggi membuat model memprediksi mahasiswa lulus tepat waktu, padahal kondisi sebenarnya tidak. Sementara itu, pada data 443, 290, dan 89, model memprediksi tidak lulus tepat waktu, sedangkan kondisi aktualnya lulus tepat waktu. Kesalahan ini terjadi karena model mempertimbangkan kombinasi seluruh fitur seperti IPK, kehadiran, dan jam belajar berdasarkan pola yang dipelajari dari data training.

C.1 Rekomendasi Model

Gaussian Naive Bayes memperoleh hasil terbaik dengan:

- **Accuracy:** 77%
- **Precision:** 77,55%
- **Recall:** 76%
- **F1-Score:** 76,77%

Model mampu memberikan prediksi yang lebih baik dibandingkan Decision Tree max_depth=3 maupun Decision Tree max_depth=None.

C.2 Bias dan Etika

Dalam penggunaan model Machine Learning, terdapat beberapa aspek yang perlu diperhatikan, terutama pada variabel **Penghasilan_Ortu** dan **Jenis_Kelamin**.

1. Penghasilan Orang Tua

Variabel **Penghasilan_Ortu** berpotensi menimbulkan bias karena kondisi ekonomi mahasiswa dapat berkaitan dengan akses terhadap fasilitas pendidikan, lingkungan belajar, maupun status beasiswa.

Jika model digunakan untuk menentukan **penerima beasiswa**, penggunaan penghasilan orang tua secara langsung dapat menyebabkan keputusan yang tidak adil apabila model terlalu bergantung pada pola ekonomi tertentu.

2. Jenis Kelamin

Variabel **Jenis_Kelamin** juga perlu diperhatikan karena model dapat mempelajari pola tertentu dari data historis yang belum tentu menunjukkan hubungan sebab-akibat. Hal tersebut dapat menyebabkan model memberikan prediksi yang berbeda berdasarkan kelompok gender.

Upaya Mitigasi Bias

Beberapa langkah yang dapat dilakukan untuk mengurangi risiko bias adalah:

1. Melakukan evaluasi performa model berdasarkan kelompok mahasiswa.
2. Memastikan variabel sensitif tidak menjadi faktor utama dalam pengambilan keputusan.
3. Mengevaluasi kembali apakah **Jenis_Kelamin** dan **Penghasilan_Ortu** memang diperlukan untuk tujuan prediksi.

Kesimpulan Etika

Model Machine Learning dapat membantu kampus melakukan deteksi awal terhadap mahasiswa yang berpotensi tidak lulus tepat waktu. Namun, penggunaannya harus memperhatikan **keadilan, transparansi, dan potensi bias**, terutama ketika data sosial seperti penghasilan orang tua dan jenis kelamin digunakan dalam proses prediksi.